

O modelo demonstrou uma eficácia excepcional na classificação de doenças cardíacas, tendo em mente que os dados de validação chegaram próximos de 92%, mostrando que as redes neurais são capazes de identificar relações complexas entre variáveis clínicas. Além disso, o uso de regularização de L2 e *Dropout* contribuíram para reduzir o risco de *overfitting*, mantendo o desempenho consistente entre treino e teste. É fundamental mencionar que a conversão para binário simplificou o problema e apresentou resultados sólidos, o que reforça a consistência do método.

Além disso, a normalização dos dados foi fundamental para assegurar estabilidade no treinamento e maximizar a performance, uma vez que as variáveis ficassem na mesma escala, o que evitou que atributos com valores maiores (como colesterol e pressão arterial) prejudiquem o processo de aprendizado. É fundamental mencionar que foi utilizado o *StandardScaler* para padronizar os dados com média zero e desvio padrão igual a um. Além disso, vale mencionar que, sem a normalização o treinamento poderia apresentar convergência lenta, instabilidade e até mesmo resultados incorretos, pois os pesos da própria rede seriam ajustados de forma desbalanceada.